TUGAS PROGRAM STUDI INDEPENDEN

ORBIT FUTURE ACADEMY

Identitas

1. Nama : Diana Eka Riyani
2. NIM : 24010119140041
3. Asal Kampus : Universitas Diponegoro
4. Kelas : Jupyter XXI
5. Coach : Ipin Sugiyarto
6. Program : Foundations of AI and Life Skills for Gen-Z
7. Hari, Tanggal : Selasa, 15 Maret 2022

Coding SL Regresi

Tugas 1: Mencoba Melakukan Scatter Plot untuk Administration dan R&D Spend

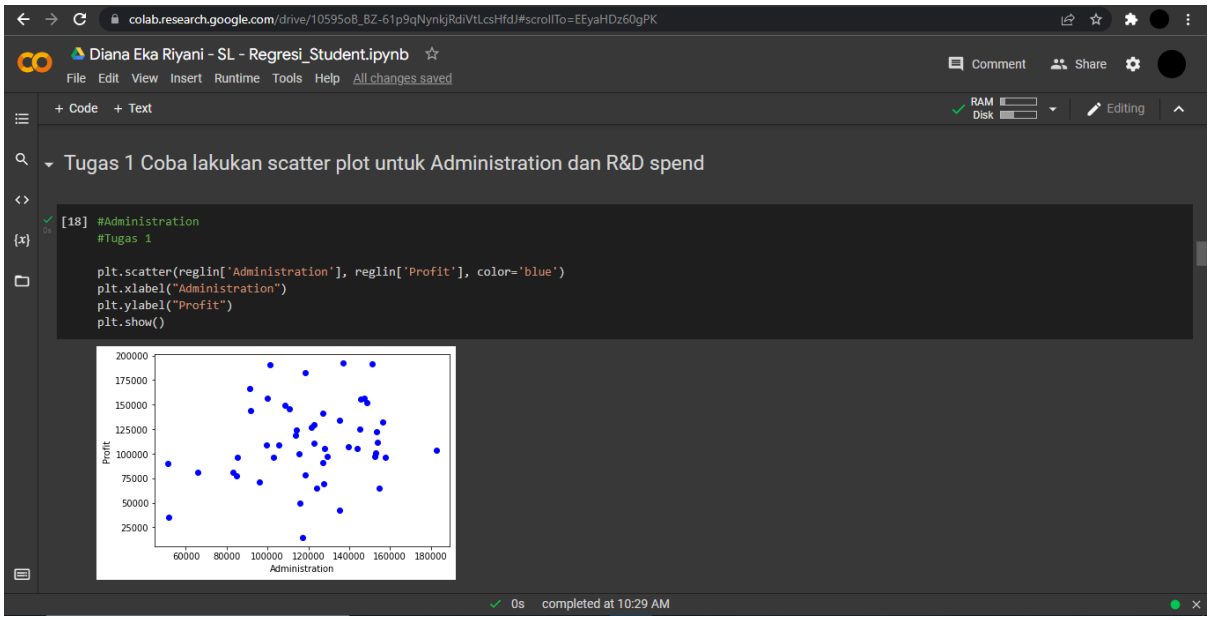

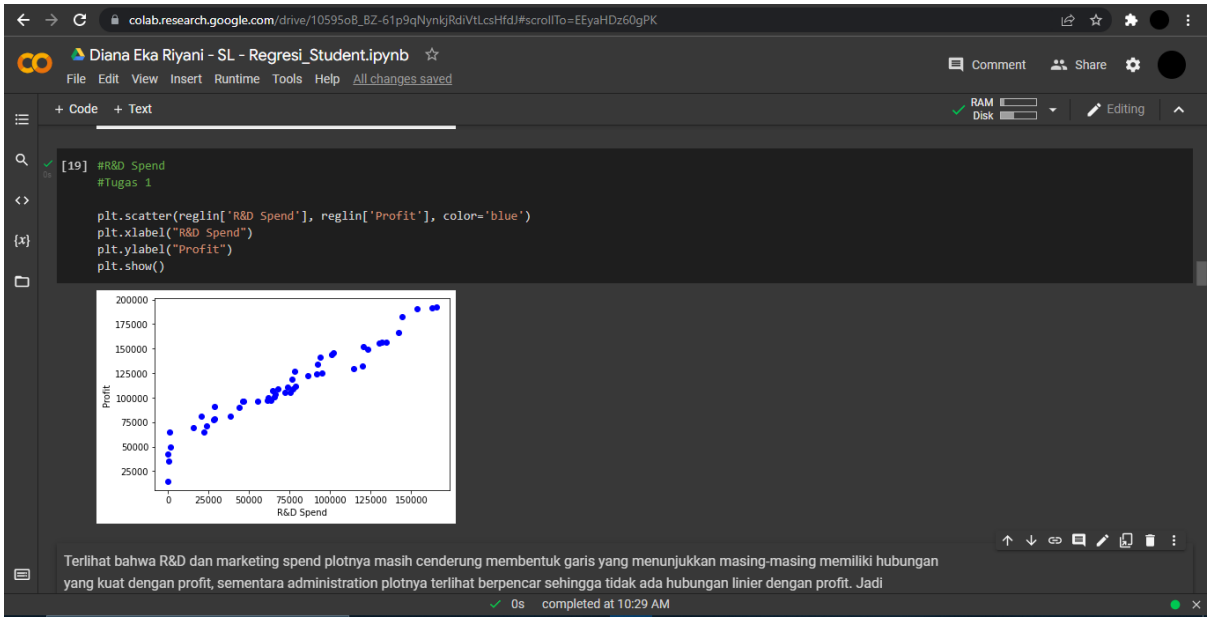

Terlihat bahwa R&D dan marketing spend plotnya masih cenderung membentuk garis yang menunjukkan masing-masing memiliki hubungan yang kuat dengan profit. Sementara administration plotnya terlihat berpencar sehingga tidak ada hubungan linier dengan profit. Jadi, kedepannya variabel yang digunakan sebagai feature adalah R&D dan marketing spend.

Tugas 2: Melakukan Splitting Data

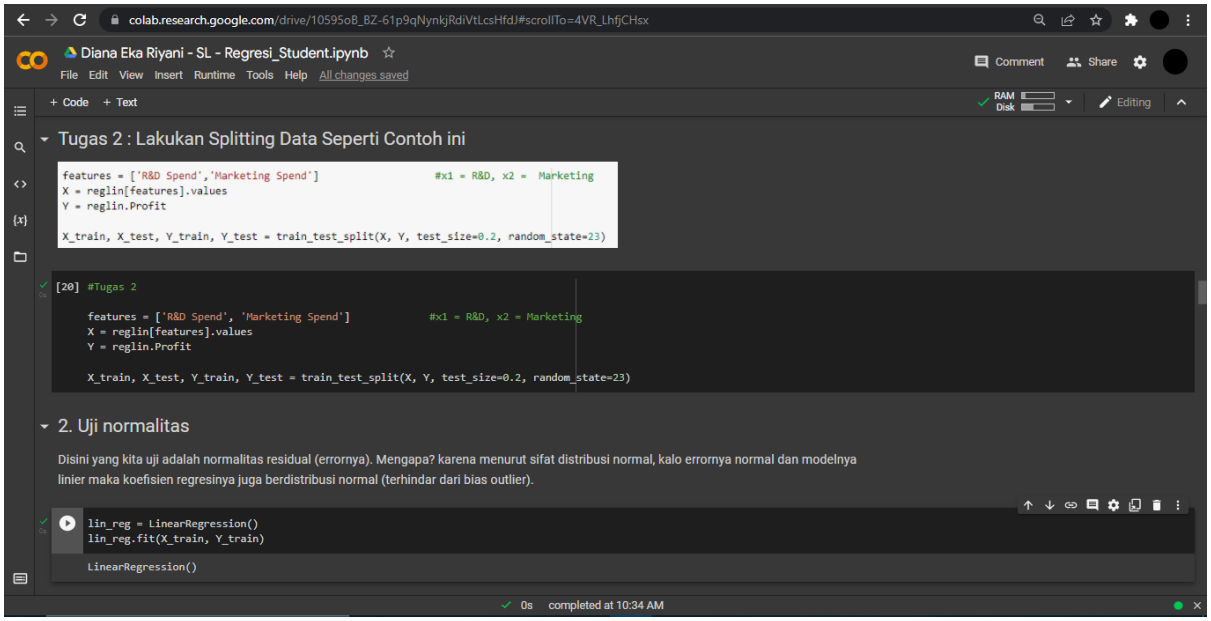

Tugas 3: Uji Normalitas

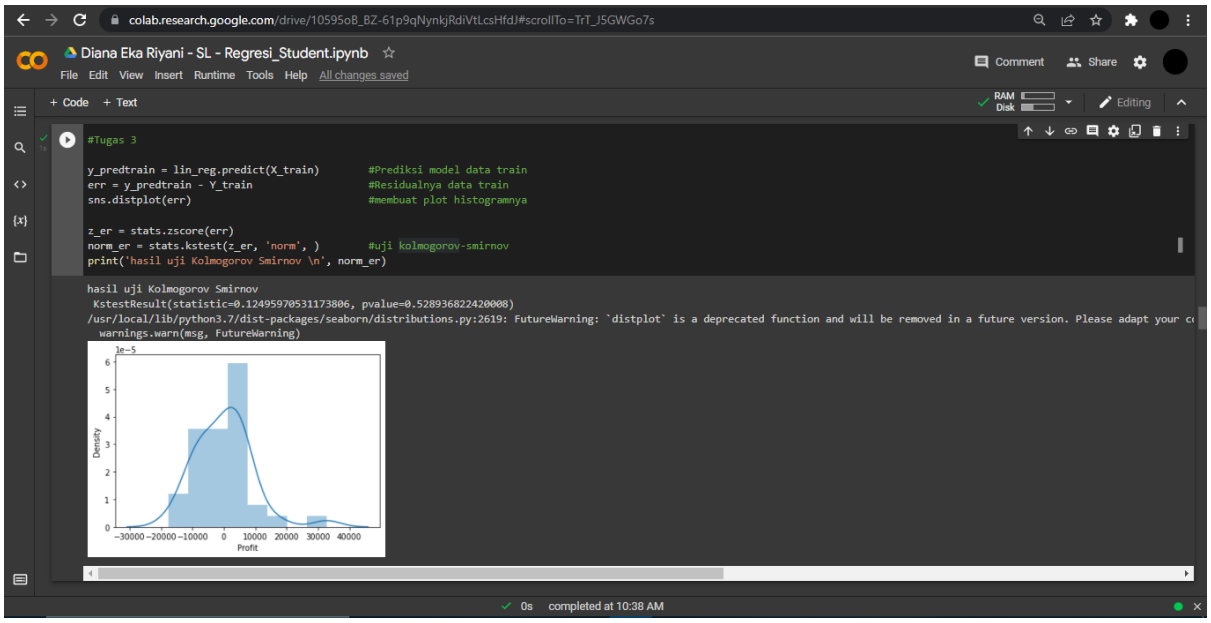

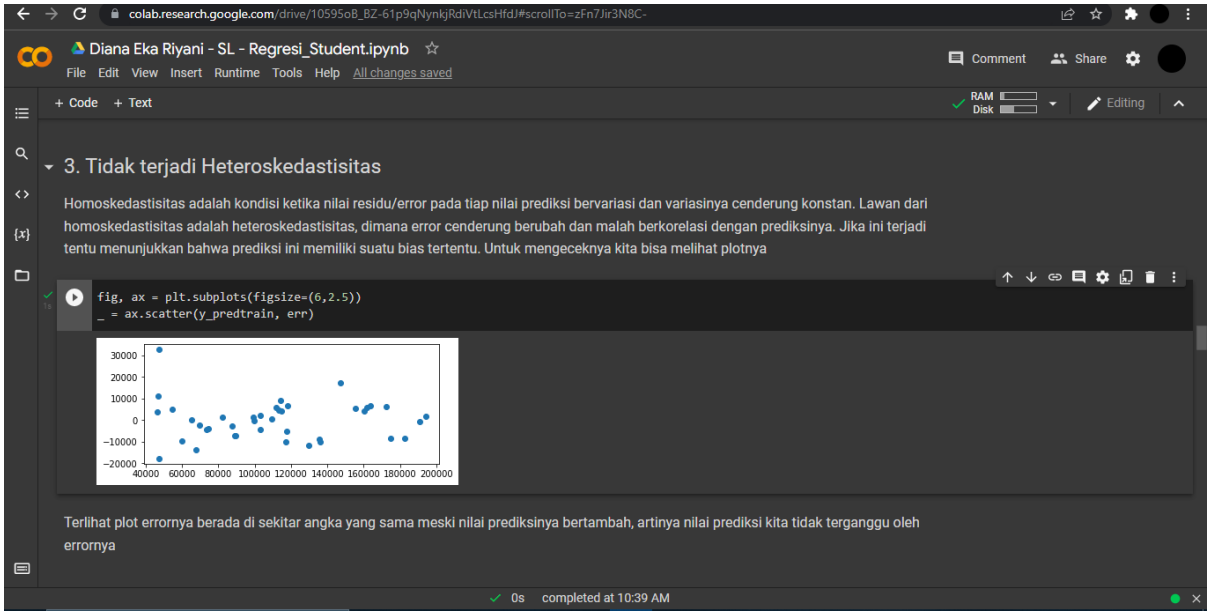

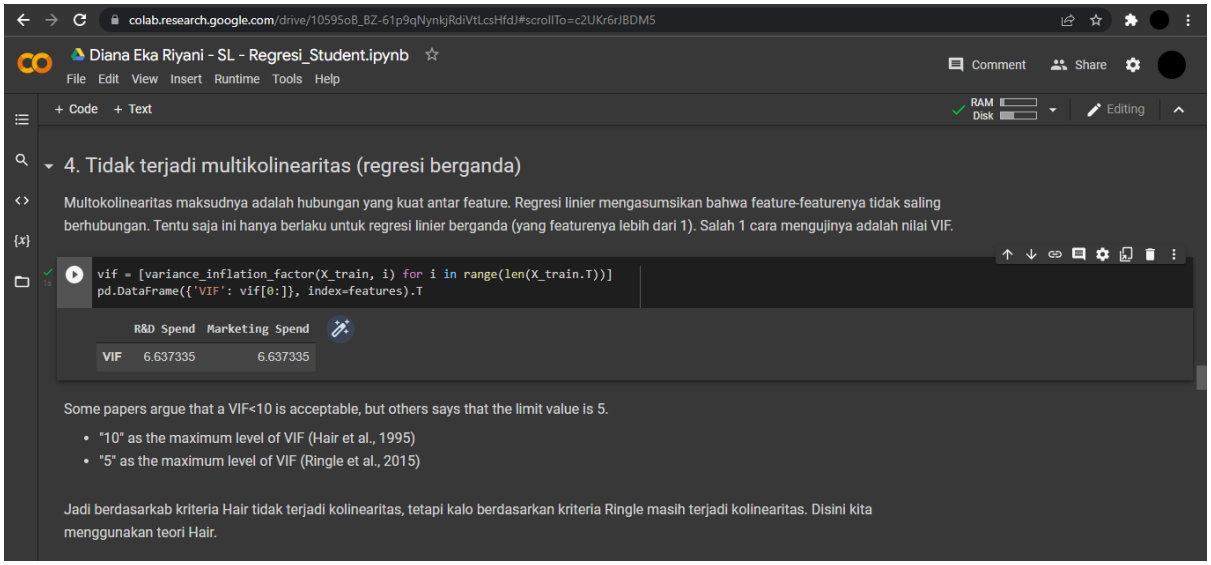
colab.research.google.com/drive/10595oB_BZ-61p9qNynkjRdiVtLcsHfdJ#scrollTo=c2UKr6rJBDM5
Diana Eka Riyani - SL - Regresi_Student.ipynb
File Edit View Insert Runtime Tools Help
Comment
Share
+ Code + Text
RAM
Disk
Editing
4. Tidak terjadi multikolinearitas (regresi berganda)
Multokolinearitas maksudnya adalah hubungan yang kuat antar feature. Regresi linier mengasumsikan bahwa feature-featurenya tidak saling berhubungan. Tentu saja ini hanya berlaku untuk regresi linier berganda (yang featurenya lebih dari 1). Salah 1 cara mengujinya adalah nilai VIF.
vif = [variance_inflation_factor(X_train, i) for i in range(len(X_train.T))]
pd.DataFrame({'VIF': vif[0:]}, index=features).T
R&D Spend
Marketing Spend
VIF
6.637335
6.637335
Some papers argue that a VIF<10 is acceptable, but others says that the limit value is 5.
"10" as the maximum level of VIF (Hair et al., 1995)
"5" as the maximum level of VIF (Ringle et al., 2015)
Jadi berdasarkab kriteria Hair tidak terjadi kolinearitas, tetapi kalo berdasarkan kriteria Ringle masih terjadi kolinearitas. Disini kita menggunakan teori Hair.

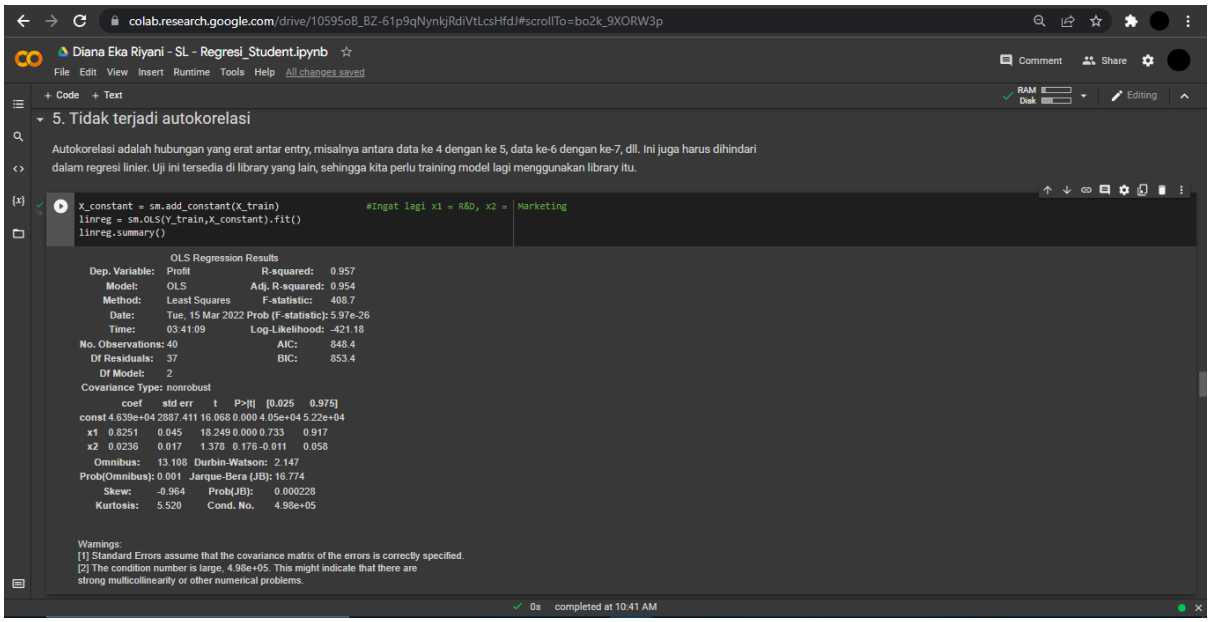
colab.research.google.com/drive/10595oB_BZ-61p9qNynkjRdiVtLcsHfdJ#scrollTo=bo2k_9XORW3p
Diana Eka Riyani - SL - Regresi_Student.ipynb
File Edit View Insert Runtime Tools Help All changes saved
Comment
Share
+ Code + Text
RAM
Disk
Editing
5. Tidak terjadi autokorelasi
Autokorelasi adalah hubungan yang erat antar entry, misalnya antara data ke 4 dengan ke 5, data ke-6 dengan ke-7, dll. Ini juga harus dihindari dalam regresi linier. Uji ini tersedia di library yang lain, sehingga kita perlu training model lagi menggunakan library itu.
X_constant = sm.add_constant(X_train) #Ingat lagi x1 = R&D, x2 = Marketing
linreg = sm.OLS(Y_train,X_constant).fit()
linreg.summary()
OLS Regression Results
Dep. Variable: Profit R-squared: 0.957
Model: OLS Adj. R-squared: 0.954
Method: Least Squares F-statistic: 408.7
Date: Tue, 15 Mar 2022 Prob (F-statistic): 5.97e-26
Time: 03:41:09 Log-Likelihood: -421.18
No. Observations: 40 AIC: 848.4
Df Residuals: 37 BIC: 853.4
Df Model: 2
Covariance Type: nonrobust
coef std err t P>|t| [0.025 0.975]
const 4.639e+04 2887.411 16.068 0.000 4.05e+04 5.22e+04
x1 0.8251 0.045 18.249 0.000 0.733 0.917
x2 0.0236 0.017 1.378 0.176 -0.011 0.058
Omnibus: 13.108 Durbin-Watson: 2.147
Prob(Omnibus): 0.001 Jarque-Bera (JB): 16.774
Skew: -0.964 Prob(JB): 0.000228
Kurtosis: 5.520 Cond. No. 4.98e+05
Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 4.98e+05. This might indicate that there are strong multicollinearity or other numerical problems.
0s completed at 10:41 AM

Tugas 4: Evaluasi Model

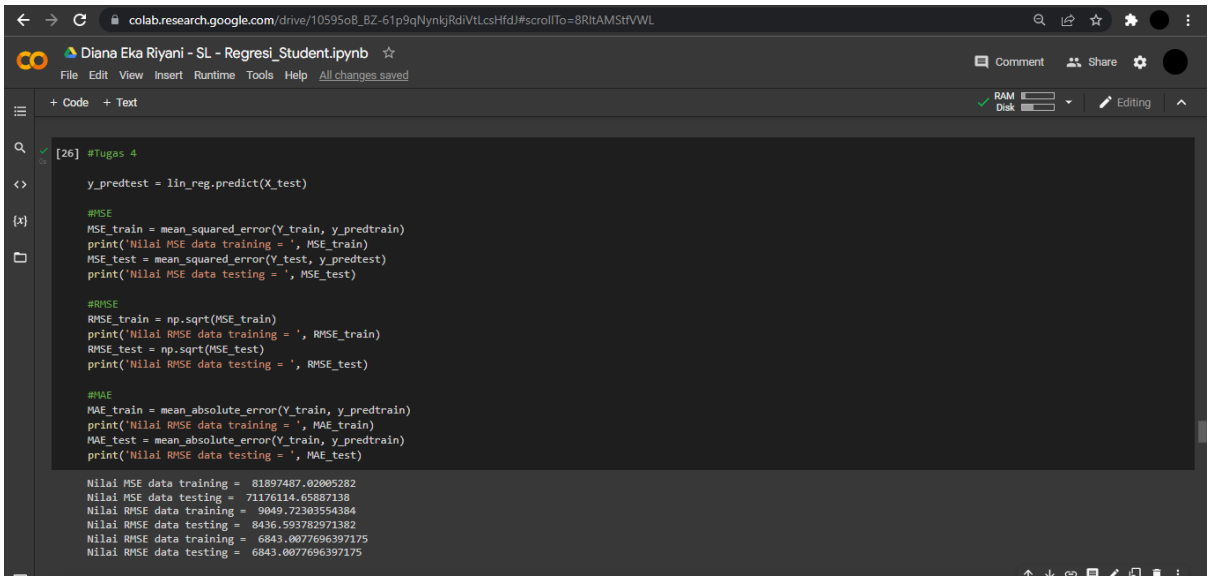

Untuk mengetahui apakah nilai ini cukup bagus atau tidak, kita perlu membuat model regresi yang lain lalu membandingkan MSE, RMSE, dan MAE-nya. Model terbaik adalah yang MSE, RMSE, dan MAE-nya paling kecil.

Tugas 5: Visualisasi Prediksi

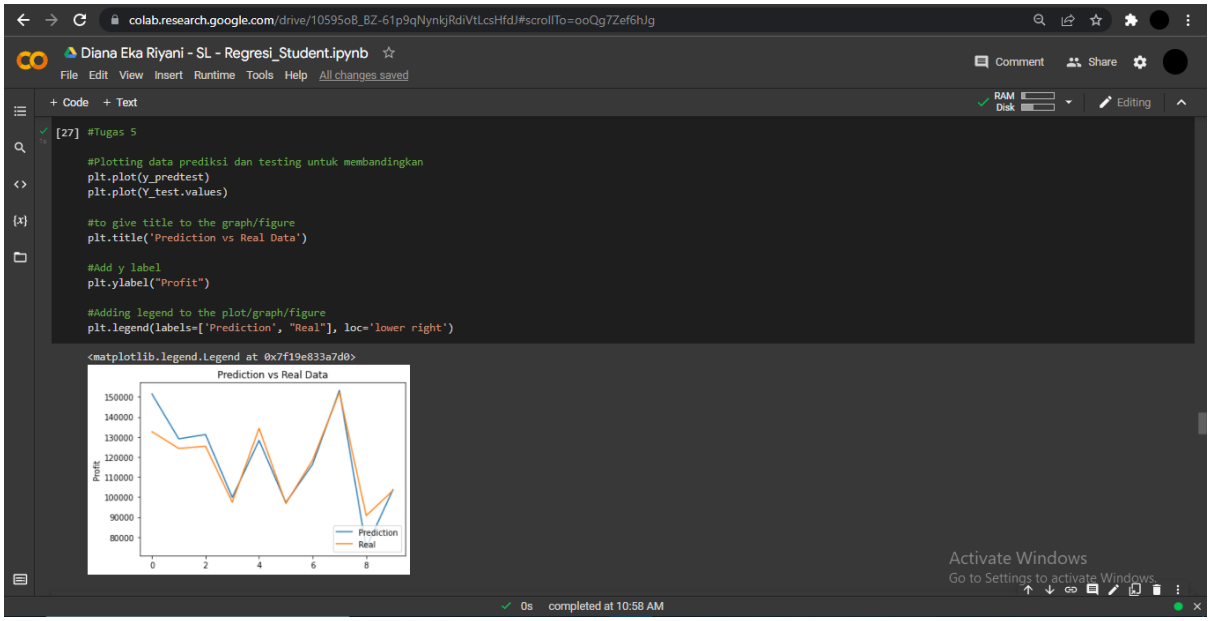

Terlihat bahwa nilai prediksi dan data testing juga cukup dekat.

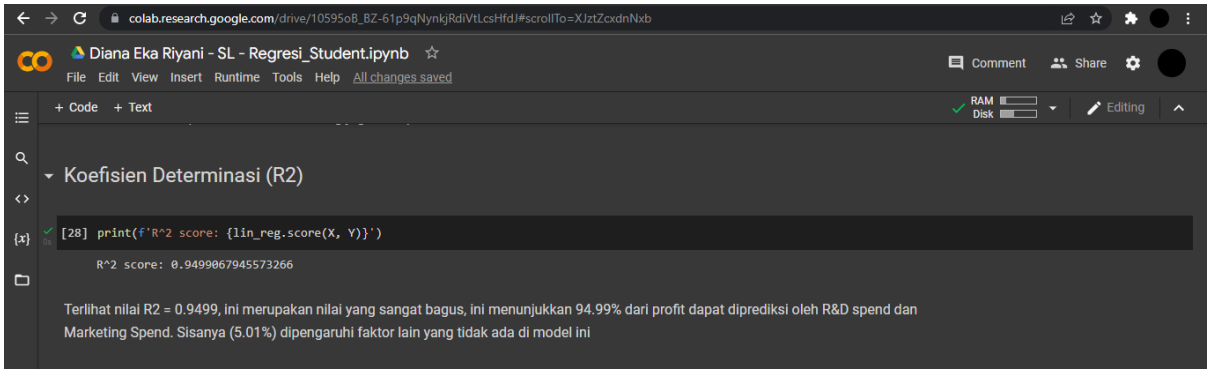
colab.research.google.com/drive/10595oB_BZ-61p9qNynkjRdiVtLcsHfdJ#scrollTo=XJztZcxdnNxb
Diana Eka Riyani - SL - Regresi_Student.ipynb
File Edit View Insert Runtime Tools Help All changes saved
Comment
Share
+ Code + Text
RAM
Disk
Editing
Koefisien Determinasi (R2)
[28] print(f'R^2 score: {lin_reg.score(X, Y)}')
R^2 score: 0.9499067945573266
Terlihat nilai R2 = 0.9499, ini merupakan nilai yang sangat bagus, ini menunjukkan 94.99% dari profit dapat diprediksi oleh R&D spend dan Marketing Spend. Sisanya (5.01%) dipengaruhi faktor lain yang tidak ada di model ini

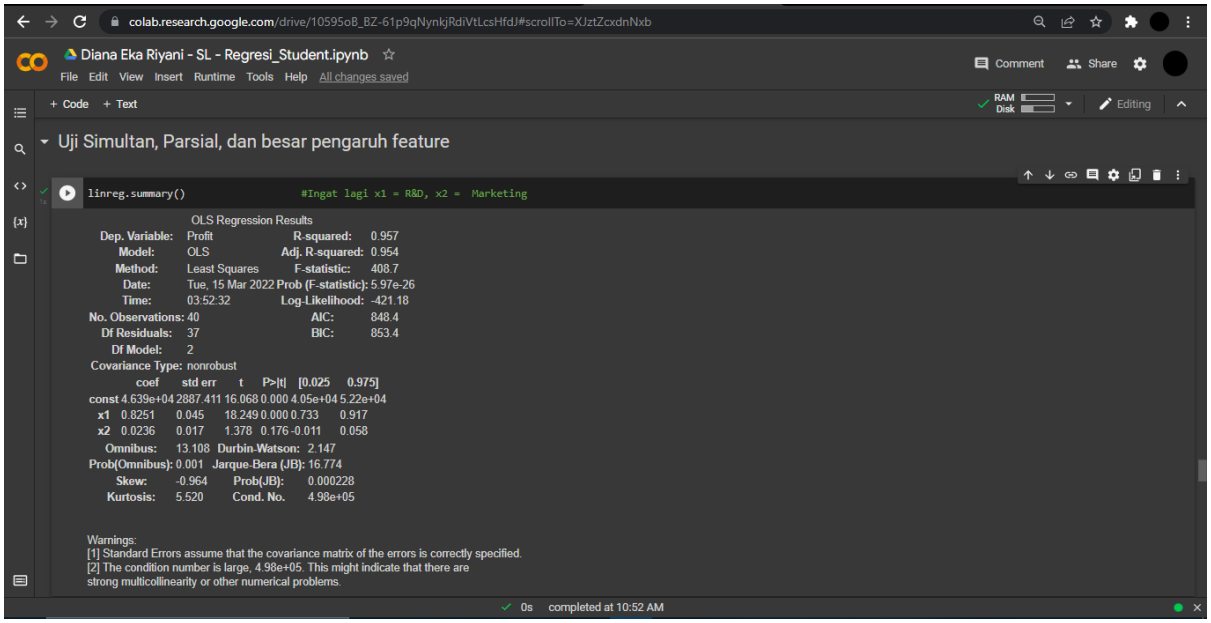
colab.research.google.com/drive/10595oB_BZ-61p9qNynkjRdiVtLcsHfdJ#scrollTo=XJztZcxdnNxb
Diana Eka Riyani - SL - Regresi_Student.ipynb
File Edit View Insert Runtime Tools Help All changes saved
Comment
Share
+ Code + Text
RAM
Disk
Editing
Uji Simultan, Parsial, dan besar pengaruh feature
linreg.summary() #Ingat lagi x1 = R&D, x2 = Marketing
OLS Regression Results
Dep. Variable: Profit R-squared: 0.957
Model: OLS Adj. R-squared: 0.954
Method: Least Squares F-statistic: 408.7
Date: Tue, 15 Mar 2022 Prob (F-statistic): 5.97e-26
Time: 03:52:32 Log-Likelihood: -421.18
No. Observations: 40 AIC: 848.4
Df Residuals: 37 BIC: 853.4
Df Model: 2
Covariance Type: nonrobust
coef std err t P>|t| [0.025 0.975]
const 4.639e+04 2887.411 16.068 0.000 4.05e+04 5.22e+04
x1 0.8251 0.045 18.249 0.000 0.733 0.917
x2 0.0236 0.017 1.378 0.176 -0.011 0.058
Omnibus: 13.108 Durbin-Watson: 2.147
Prob(Omnibus): 0.001 Jarque-Bera (JB): 16.774
Skew: -0.964 Prob(JB): 0.000228
Kurtosis: 5.520 Cond. No. 4.98e+05
Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 4.98e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
0s completed at 10:52 AM

Tugas 6: Training 4 Model

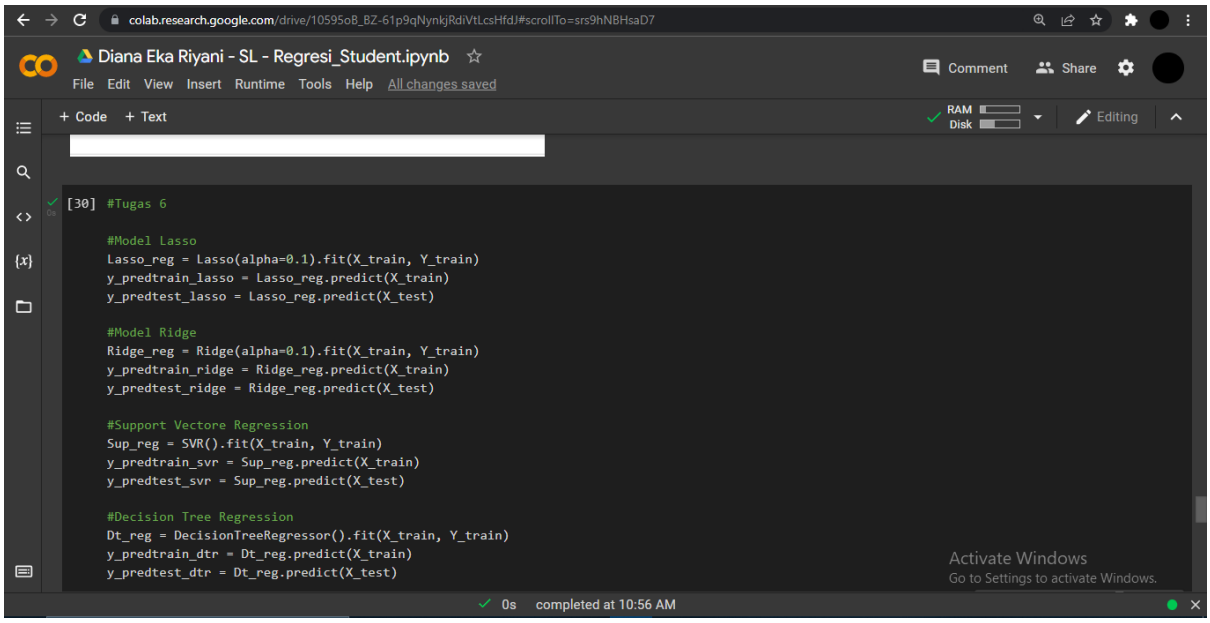

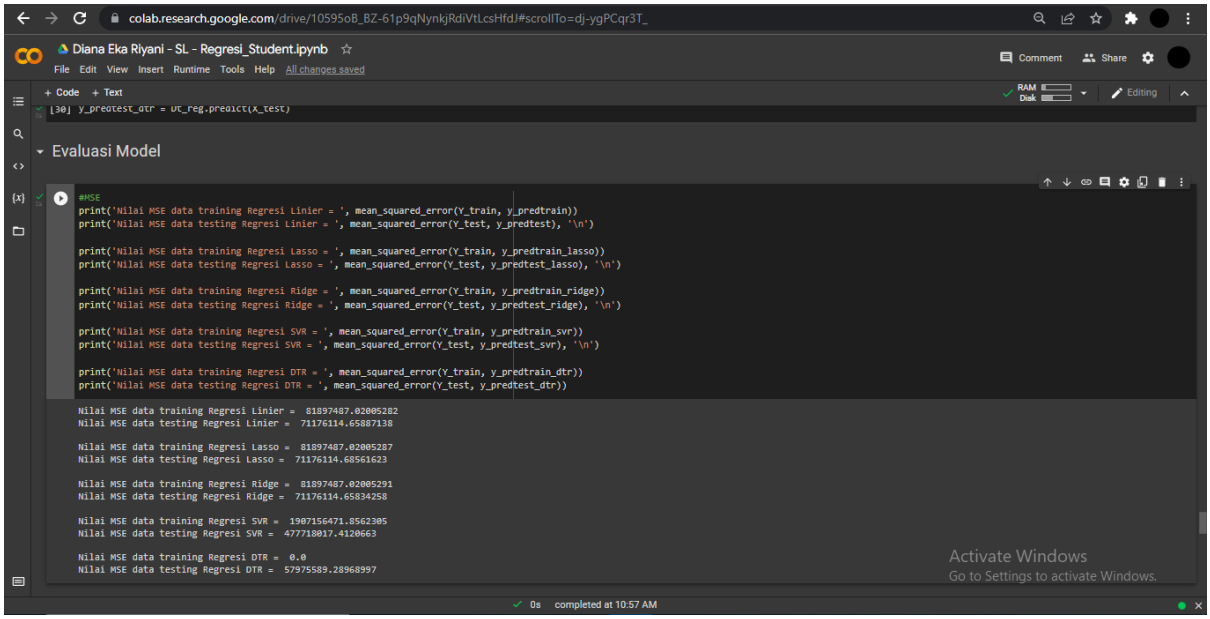

Tugas 7: Mencari Nilai R2

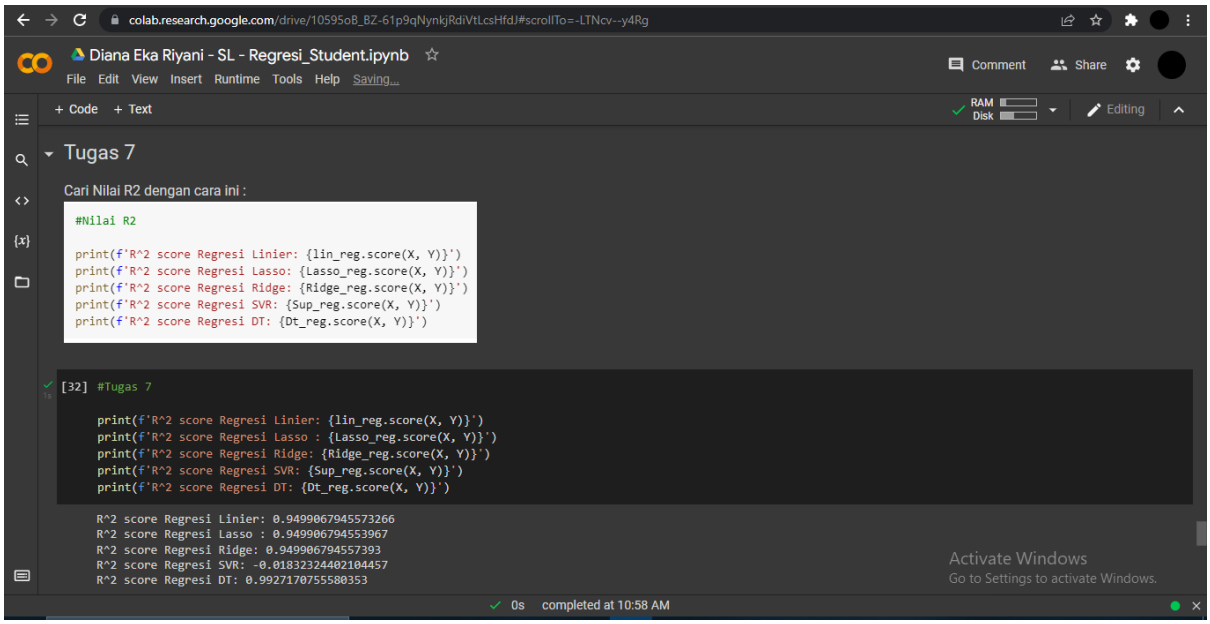

- Model regresi Support Vector Regression memiliki MSE yang terlalu tinggi dibandingkan model regresi lainnya dan R2 yang sangat rendah, sehingga kemungkinan pada model ini terjadi underfitting.
- Model regresi Decision Tree Regression R2 paling bagus, mMSE data training 0 (sangat kecil), sementara MSE data testing jauh diatasnya, ini menunjukkan pada model ini terjadi overfitting.
- Model regresi linier, regresi Lasso, dan regresi Ridge memiliki MSE yang tidak jauh antara testing dan trainingnya. Nilai R2nya pun sangat bagus, hampir 95%. Ini menunjukkan model ini sudah good fit.